Information Retrieval

05 – Index-Konstruktion

Philipp Schaer, Technische Hochschule Köln, Cologne, Germany

Version: 2022-04-28

Technology
Arts Sciences
TH Köln

Was haben wir heute vor…?

Orga-Time

- Vektor-Muster-Lösung ist (fast) online.
- Erstes Quiz ist in Moodle online. Viel Erfolg.

Leitfragen für heute

- Welche **zwei gegensätzlichen Ansätze** finden sich nahezu in allen Indexierungmodulen wieder? Gibt es hierbei **Pros** und **Cons?**
- Welche **linguistischen Module** gibt es, die den Anspruch an einen ”best match” aktiv unterstützen?
- Und **wie genau machen** das die Module jeweils?
- Welche **Pipeline** auf Folie 38 gewinnt?

Vorbemerkung zur Indexerstellung

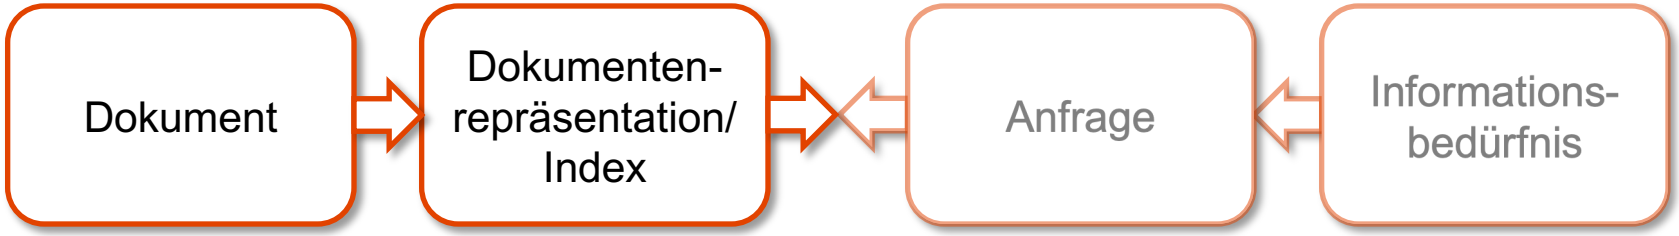

Grundfragen, die vor der Indexerstellung geklärt sein sollten

- Welches **Vorverarbeitung** (Preprocessing) muss gegeben sein um die Term-Dokumentmatrix und damit das "**Vokabular**" aufzubauen?
- Welche **Terme** kommen in den Index?

- Einiges, was Sie hier hören kennen Sie ggf. auch schon von **Herrn Lepskys Veranstaltungen bzw. werden es dort kennenlernen!**

Themen der Veranstaltung

- Indexierung – manuell vs. automatisch
- Grundlegende Indexierungspipeline
- Vorverarbeitung
- Indexerstellung – Invertierte Listen

Indexierung. Damals…

Intellektuelle Indexierung (manuell)

Basis = Dokumentationssprache (Terminologiekontrolle)

- Intellektuelle **Interpretation** des Dokumentinhalts & Verschlagwortung
- Sehr **präzise** Einordnung & Recherche möglich
- Intellektuelle **Relevanzentscheidung** beim Indexieren & Recherchieren
- Ursprung **Bibliothekswesen**: notwendig bei systematischer, physischer Ablage

Nachteile

- Aufwendig (Entwicklung & Anwendung)
- Langsam, skaliert nicht (viele Dokumente → viel Aufwand)
- Lernaufwand für den Benutzer

Automatische Indexierung

Maschinelle Prozesse der Inhaltsanalyse und -darstellung

- Vollautomatisch
- Teilautomatisch

- Vorteil: Schnelligkeit

- Für **große Textmengen**: Zur Bewältigung der Informationsflut
- Es existieren aber typische **Problembereiche**:
  - Inhaltliche Interpretation?
  - Qualität ausreichend?
  - Nicht-textuelle Medien?

Automatische Indexierung: Typologie

1. Verfahren, die **Metadaten** produzieren
   - Ausgehend von einer existierenden Dokumentationssprache
   - Ausgehend vom Dokument

2. **Verfahren, die vorhandenen Text prozessieren und für die Suche bereitstellen**

Typische Ansätze:

- **Computerlinguistisch**: Wortebene (Regeln, Wörterbücher)
- **Statistisch**: Worthäufigkeiten (weitverbreitete Methode)
- **Begriffsorientiert**: Begriffsebene

Übersicht über Indexierungsverfahren

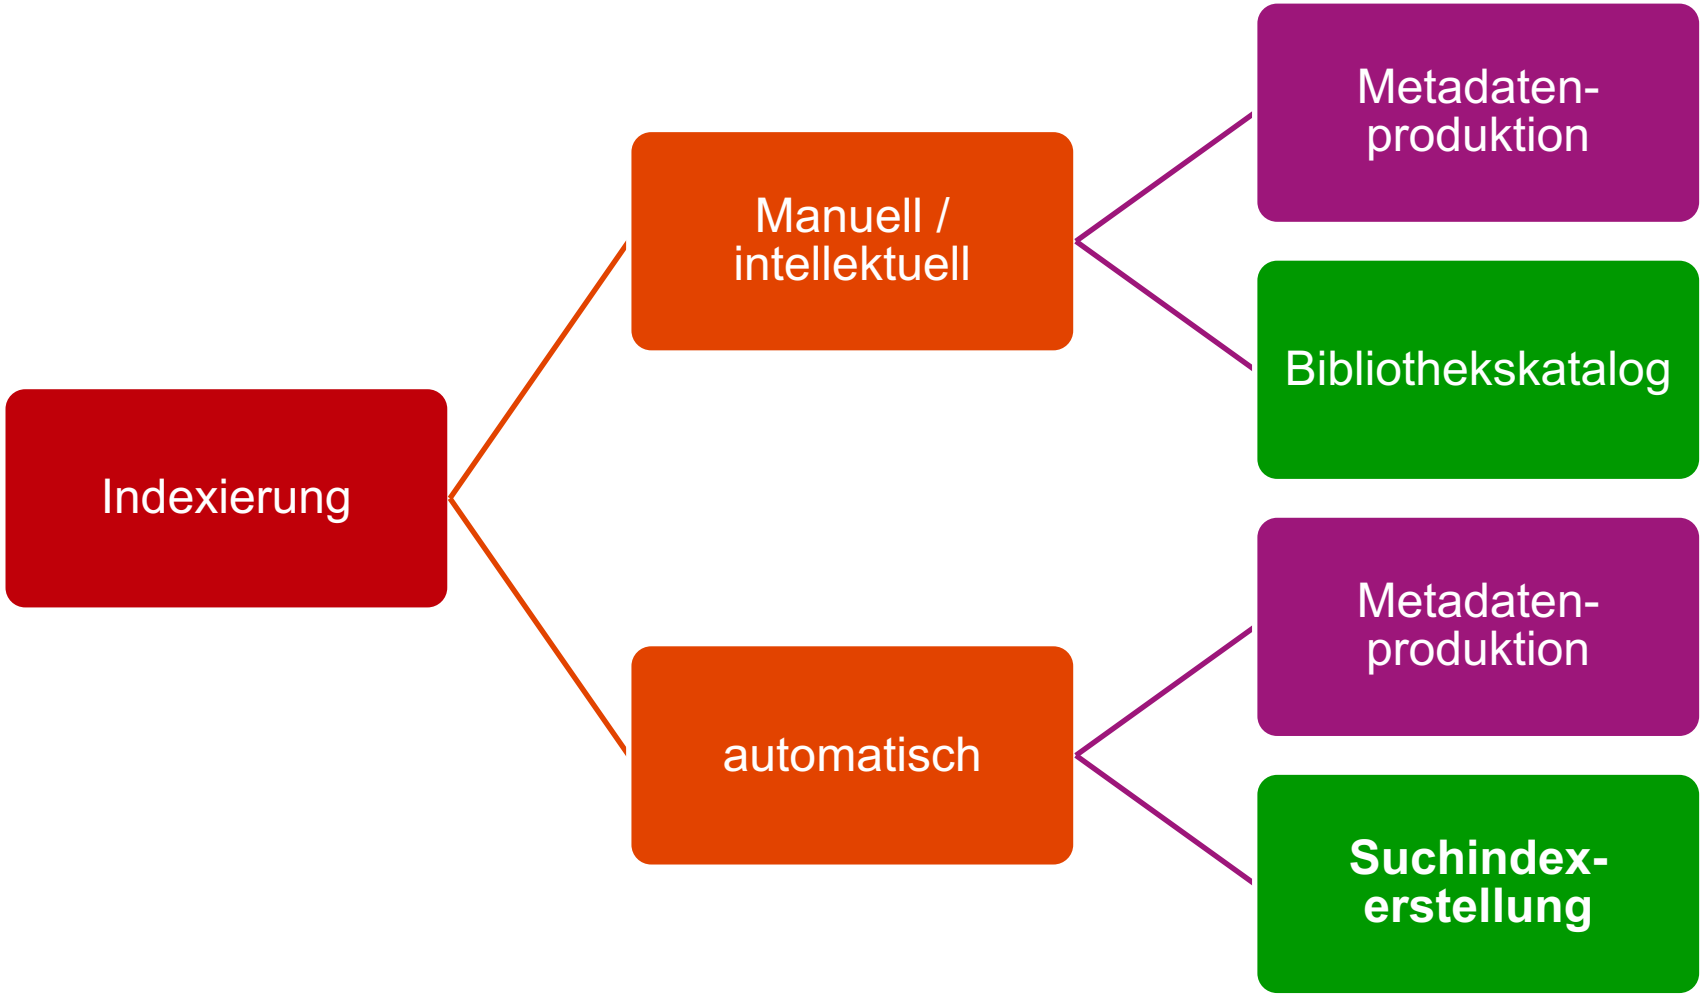

Definitionen

Wort

- Eine begrenzt lange Buchstabenreihung in einem Text.

Term

- Ein normalisiertes Wort; eine Äquivalenzklasse von Wörtern.

Token

- Eine Instanz / konkrete Nutzung eines Worts oder Terms in einem Dokument.

Grundlegende Indexierungspipeline

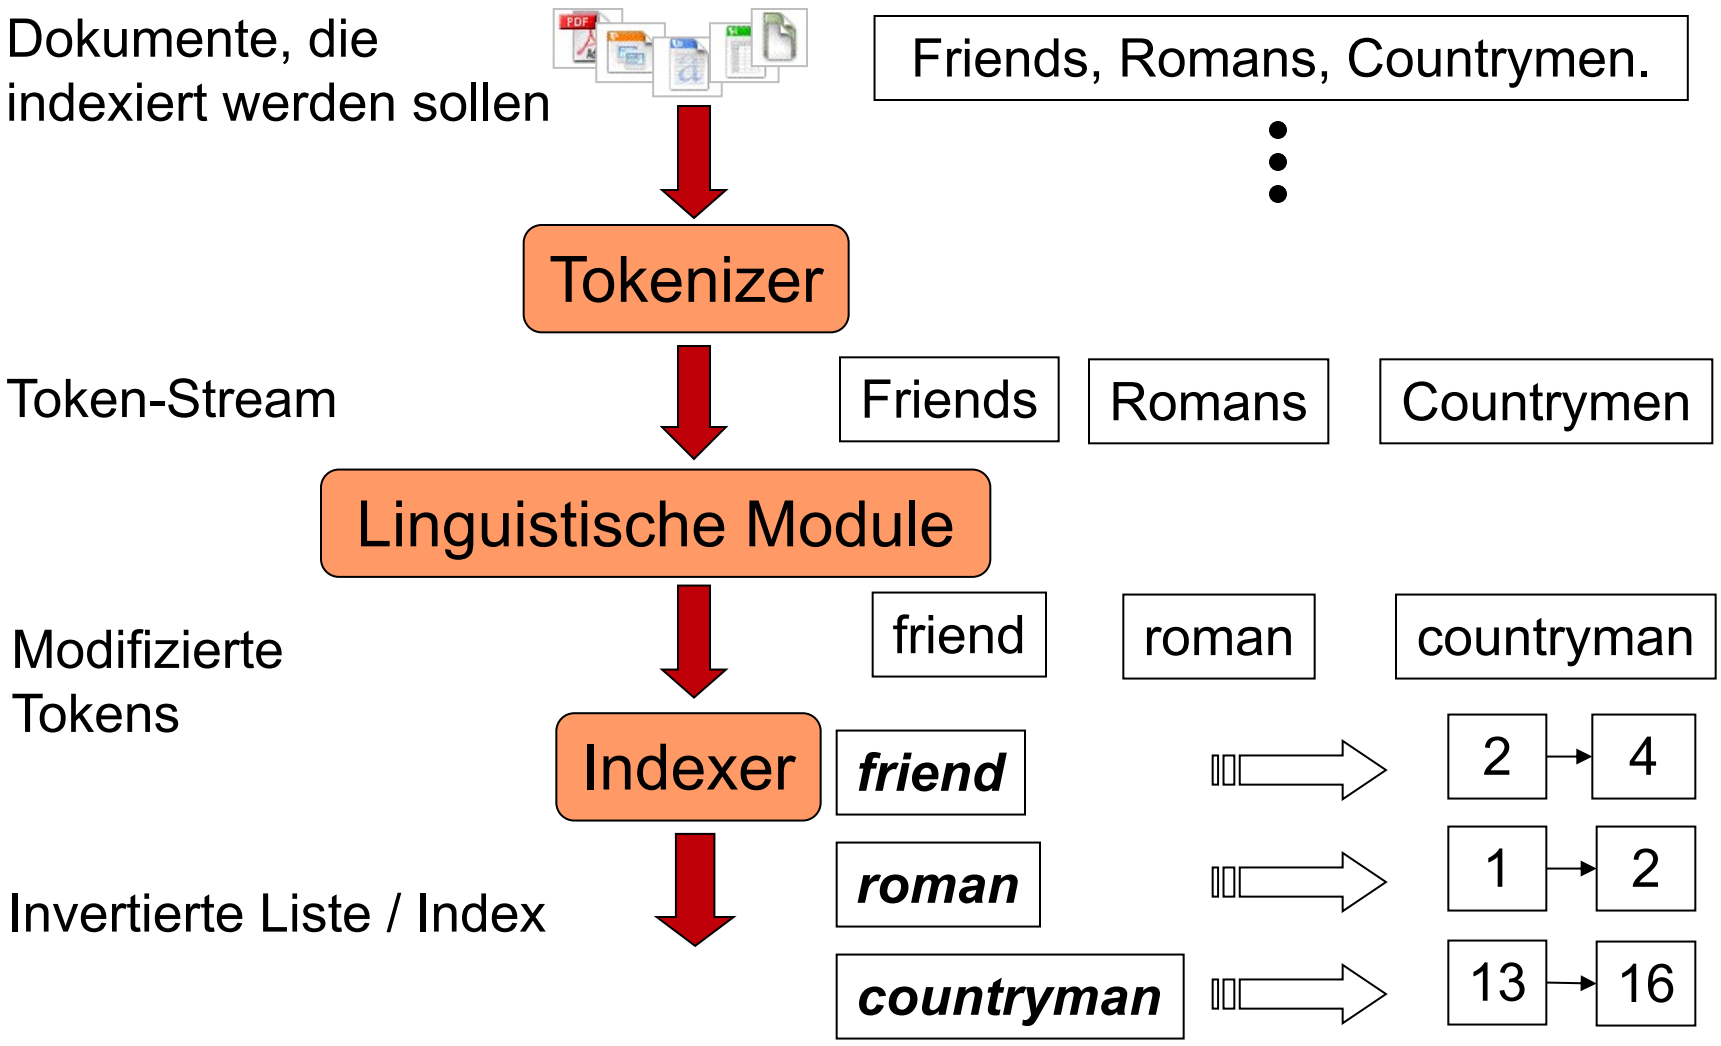

Indexer Verarbeitungsschritte

Erstellen einer Sequenz aus Term-Dokument-ID-Paaren.

Doc 1

I did enact Julius Caesar
I was killed i' the Capitol;
Brutus killed me.

Doc 2

So let it be with Caesar.
The noble Brutus hath told
you Caesar was ambitious

Term	Doc #
I	1
did	1
enact	1
julius	1
caesar	1
I	1
was	1
killed	1
i'	1
the	1
capitol	1
brutus	1
killed	1
me	1
so	2
let	2
it	2
be	2
with	2
caesar	2
the	2
noble	2
brutus	2
hath	2
told	2
you	2
caesar	2
was	2
ambitious	2

Indexer Verarbeitungsschritte

Term	Doc #
I	1
did	1
enact	1
julius	1
caesar	1
I	1
was	1
killed	1
i'	1
the	1
capitol	1
brutus	1
killed	1
me	1
so	2
let	2
it	2
be	2
with	2
caesar	2
the	2
noble	2
brutus	2
hath	2
told	2
you	2
caesar	2
was	2
ambitious	2

Sortieren der Sequenz

Term	Doc #
ambitious	2
be	2
brutus	1
brutus	2
capitol	1
caesar	1
caesar	2
caesar	2
did	1
enact	1
hath	1
I	1
I	1
i'	1
it	2
julius	1
killed	1
killed	1
let	2
me	1
noble	2
so	2
the	1
the	2
told	2
you	2
was	1
was	2
with	2

Mehrfache Begriffe werden **vereinigt** und die **Frequenz** gespeichert

Term	Doc #	Term freq
ambitious	2	1
be	2	1
brutus	1	1
brutus	2	1
capitol	1	1
caesar	1	1
caesar	2	2
did	1	1
enact	1	1
hath	2	1
I	1	2
i'	1	1
it	2	1
julius	1	1
killed	1	2
let	2	1
me	1	1
noble	2	1
so	2	1
the	1	1
the	2	1
told	2	1
you	2	1
was	1	1
was	2	1
with	2	1

Aufteilung in Dictonary und Postings

Term	Doc #	Freq
ambitious	2	1
be	2	1
brutus	1	1
brutus	2	1
capitol	1	1
caesar	1	1
caesar	2	2
did	1	1
enact	1	1
hath	2	1
I	1	2
i'	1	1
it	2	1
julius	1	1
killed	1	2
let	2	1
me	1	1
noble	2	1
so	2	1
the	1	1
the	2	1
told	2	1
you	2	1
was	1	1
was	2	1
with	2	1

Term	N docs	Coll freq
ambitious	1	1
be	1	1
brutus	2	2
capitol	1	1
caesar	2	3
did	1	1
enact	1	1
hath	1	1
I	1	2
i'	1	1
it	1	1
julius	1	1
killed	1	2
let	1	1
me	1	1
noble	1	1
so	1	1
the	2	2
told	1	1
you	1	1
was	2	2
with	1	1

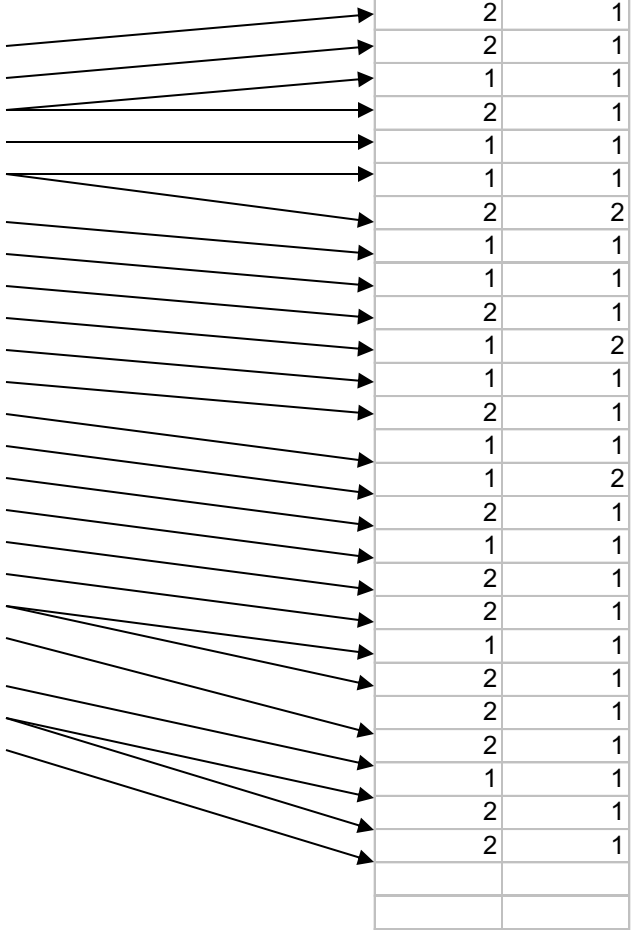

Doc #	Freq
2	1
2	1
1	1
2	1
1	1
1	1
2	2
1	1
1	1
2	1
1	2
1	1
2	1
1	1
1	2
2	1
1	1
2	1
2	1
1	1
2	1
2	1
2	1
1	1
2	1
2	1

Konstruktion invertierte Liste / Index

Für jeden Term *t* speichern wir die Dok-IDs, in denen *t* vorkommt.

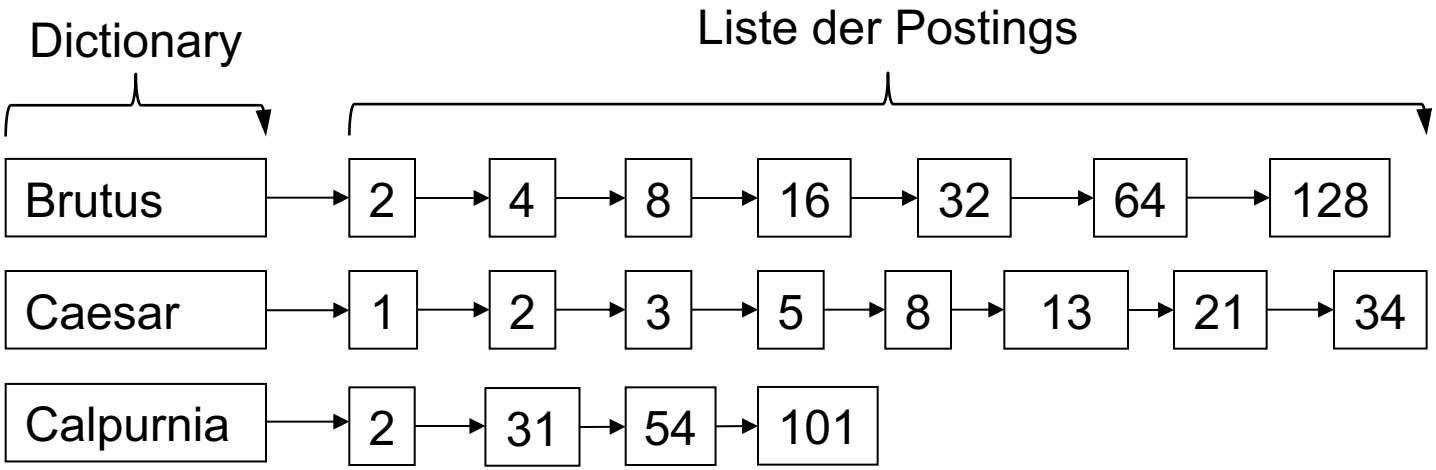

Übrigens! Es ist entweder eine invertierte Liste **oder** ein Index; einen invertierten Index gibt es nicht (das wäre doppelt-gemoppelt).

Eine Anfrage an den Index stellen

Wird eine Anfrage mit zwei Termen gestellt (Brutus AND Caesar), werden beide Postings simultan abgearbeitet und bei einer Übereinstimmung der Einträge das Ergebnis gespeichert.

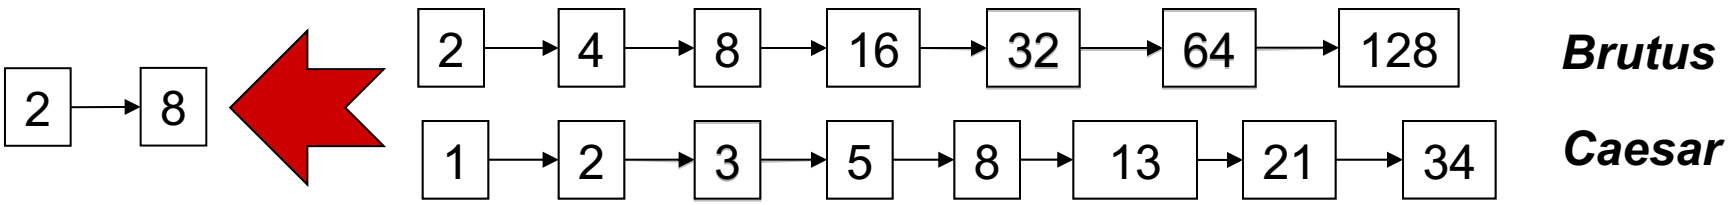

Wenn die Listen die Länge x und y haben, dann benötigt der Vergleich max. **O(*x*+*y*) Operationen**.

Wichtig: Hierzu müssen die Liste der Postings sortiert sein!

Exkurs: O-Notation

- Die O-Notation beschreibt die Komplexität / Laufzeit eines Algorithmus
- Grundsätzlich muss man Eingabe (Input), Ausgabe (Output) und die Verarbeitungszeit (Processing Time) betrachten

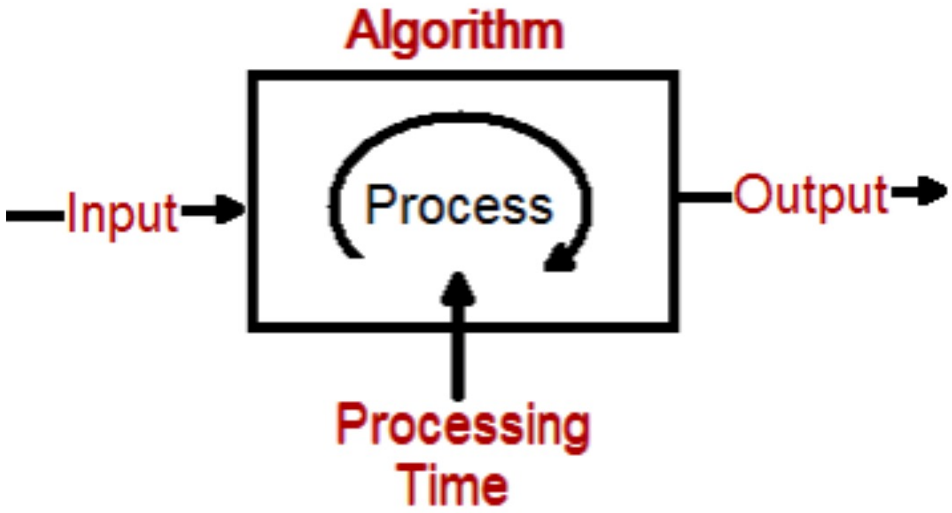

https://stackoverflow.com/questions/487258/what-is-a-plain-english-explanation-of-big-o-notation/50288253#50288253

O-Notation: Beispiel

- Ein Algorithmus braucht zur Verarbeitung von Records (Datensätzen, Dokumenten, o.ä.) unterschiedlich lange.
- Aus einer Messung der Verarbeitungszeit unterschiedlich großer Mengen von Records ergibt sich eine Abschätzung von $O(n^2)$.

- *Ist das gut oder schlecht?*

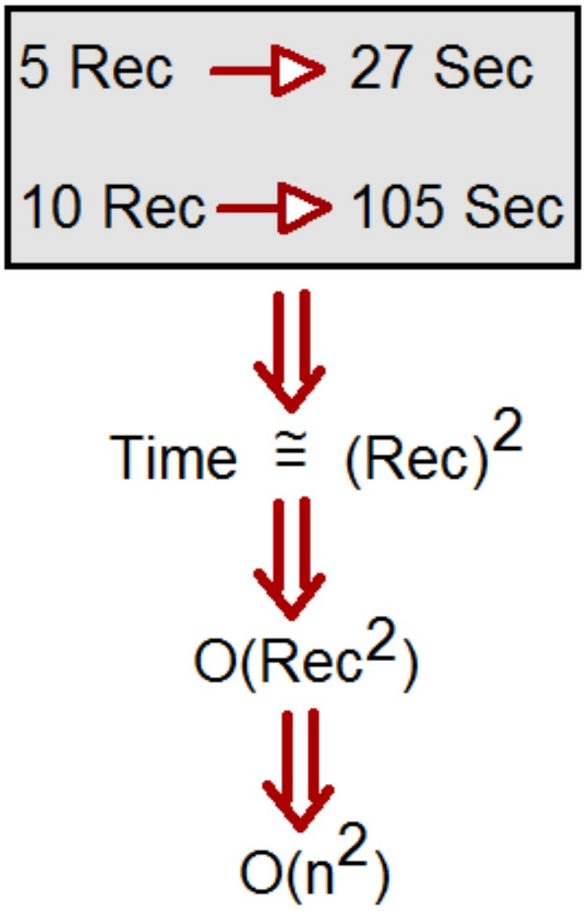

https://stackoverflow.com/questions/487258/what-is-a-plain-english-explanation-of-big-o-notation/50288253#50288253

O-Notation grafisch

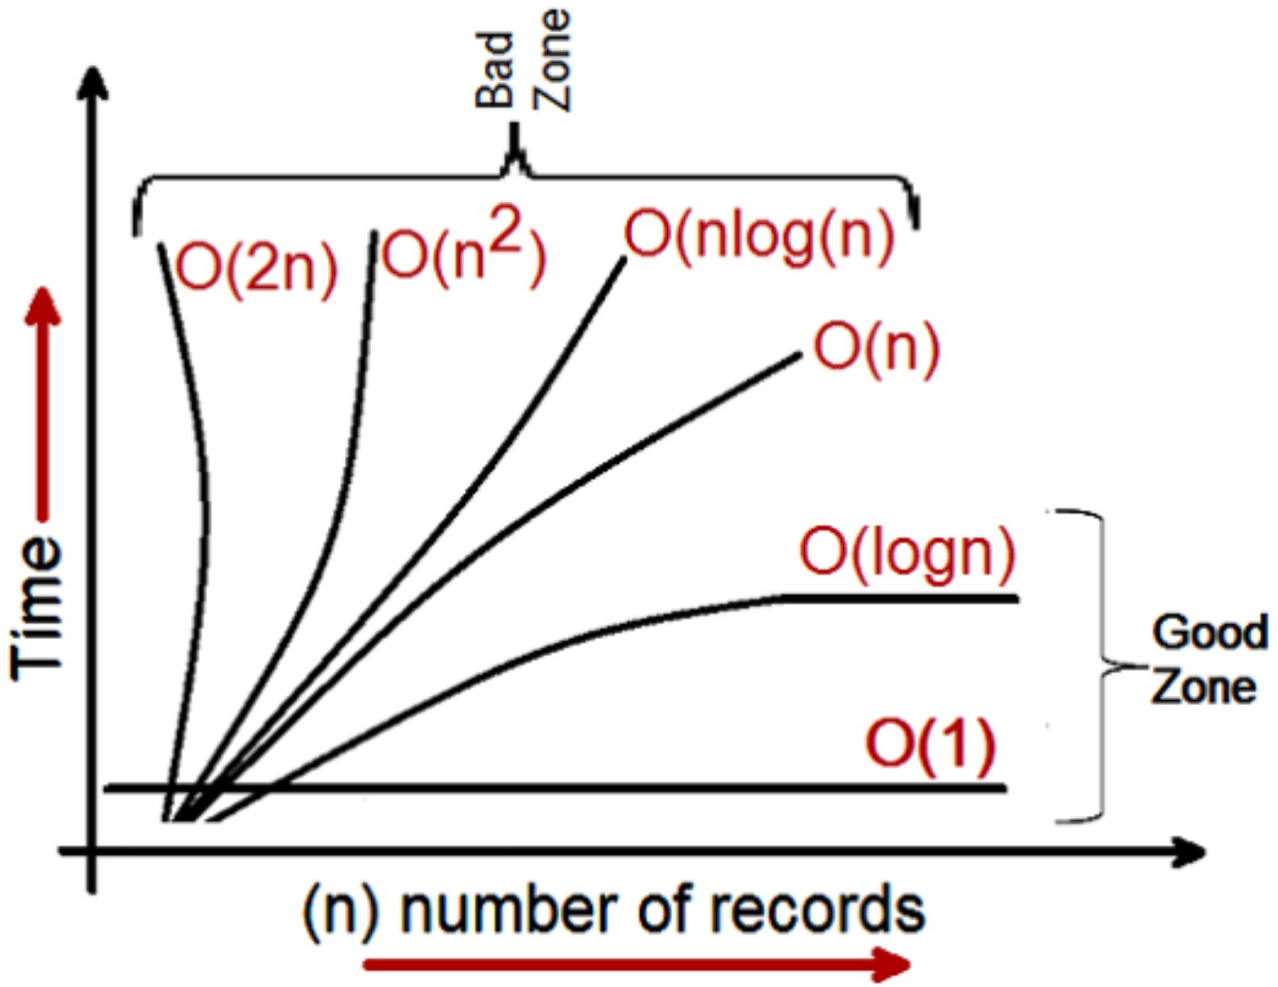

https://stackoverflow.com/questions/487258/what-is-a-plain-english-explanation-of-big-o-notation/50288253#50288253

Automatische Indexierung: Probleme

- **Sprachliche Herausforderungen**
  - Paraphrasen
  - Umgangssprache
  - Metaphern
  - Anaphern (rhetorische Wortfigur: z.B. Wiederholung)
  - Neologismen
  - Synonyme
  - Polyseme/Homonymie
- **Gewichtung der Terme im Dokument**
- **Zuordnung zu einer Dokumentationssprache**

Computerlinguistische Verfahren

Die Computerlinguistik biete eine ganze Reihe an Verfahren:

- **Tokenisierung**: Segmentierung eines Textes auf Wortebene
- **Normalisierung**:
  - Satzzeichen-Entfernung: U.S.A. | USA
  - Groß-/Kleinschreibung
- Entfernung „nicht hilfreicher“ Terme → **Stoppworte**
- Vereinheitlichung unterschiedlicher Wortformen → **Stemming** / **Lemmatization**
- **Kompositazerlegung**
- **Phrasenerkennung**
- **Eigennamenerkennung**

Stoppworte

... haben folgende Eigenschaften

- Inhaltslos
- Gleiche Wahrscheinlichkeit, in relevanten wie nichtrelevanten Dokumenten vorzukommen
- Werden aus dem Index bzw. der Anfrage entfernt (und folglich nicht weiter in Betracht gezogen)
- sprachabhängig

... kommen in unterschiedlichen Kontexten vor

- Allgemeine Stoppworte einer Sprache
- Stoppworte in einer gegebenen Dokumentmenge
- Stoppworte für einen gegebenen Zweck

Stoppworte

Erstellung

- Manuelle Liste
- Automatische Liste (Zipf)

Typische Kandidaten:

- Artikel, Konjunktionen, Präpositionen, Hilfsverben

Probleme:

„To be or not to be“

„I can open a can of tuna with a can opener.“

Wo sind die Kandidaten für Stoppworte?

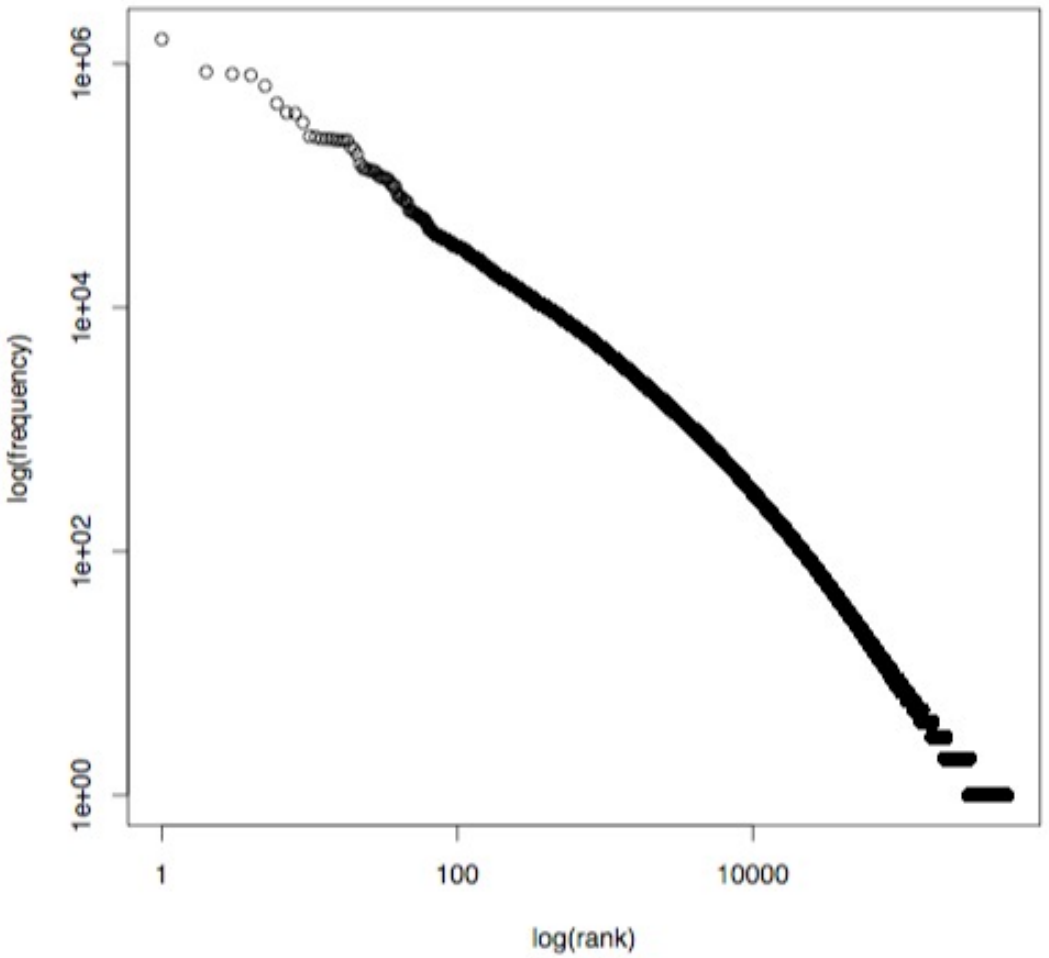

Wortform-„Verschmelzung“ (conflation)

- Varianten eines Wortes auf eine **Grundform** zurückführen
- **Wortformen** tauchen damit in Gewichtungsberechnungen als **der gleiche Term** auf

Techniken:

- Nicht-linguistisch → **Stemming**
  - Retrieved, Retrieval → Retriev
- Linguistisch → **Lemmatization**
  - Retrieved, Retrieval → Retrieve

Stemming (Wortstammbildung)

- Regeln, um Wortvarianten auf einen gemeinsamen Stamm zu reduzieren
- Sprachabhängig
- Meist Abtrennen von Suffixen
- (Präfixe = anti-, un- → Bedeutungsveränderung)

Verfahren:

- **Longest-match** → längste Endung wird in einem Schritt entfernt
- **Iterativ** → Aufeinanderfolgende, regelbasierte Entfernung / Umwandlung von Endungen
- **Korpus-basiert** → vermeidet Polysemproblem (Wortvarianten mit unterschiedlichen Bedeutungen kommen nicht im gleichen Dokument vor)

Longest-Match Stemmer (Lovins, 1968)

.11.

alistically B
arizability A
izationally B

.10.

antialness A
arisations A
arizations A
entialness A

.09.

allically C
antaneous A
antiality A
arisation A
arization A
ationally B
ativeness A
eableness E
entations A

.09.—*Cont.*

entiality A
entialize A
entiation A
ionalness A
istically A
itousness A
izability A
izational A

.08.

ableness A
arizable A
entation A
entially A
eousness A
ibleness A
icalness A
ionalism A
ionality A

Folie von Vivien Petras

Stock (2007), S. 233

Iterativ: Porter Stemmer (1980)

Step 1a

SSES	→ SS	caresses	→	caress
IES	→ I	ponies	→	poni
		ties	→	ti
SS	→ SS	caress	→	caress
S	→	cats	→	cat

Step 1b

(m>0) EED	→ EE	feed	→	feed
		agreed	→	agree
(*v*) ED	→	plastered	→	plaster
		bled	→	bled
(*v*) ING	→	motoring	→	motor
		sing	→	sing

Step 1c

(*v*) Y	→ I	happy	→	happi
		sky	→	sky

- m → Vokal-Konsonant Folge
- *v* → Stamm muss Vokal enthalten
- 5 Iterationen

Folie von Vivien Petras

Stock (2007), S. 234

Overstemming / Understemming

Understemming

- 2 Wortformen der gleichen Begriffsgruppe enden in unterschiedlichen Stems
- Divided division → divid divis

Overstemming

- 2 Wortformen unterschiedlicher Begriffsgruppen enden in gleichen Stems
- Operate operating operates operation operative operatives operational → oper
- University universe → univers

Lemmatisierung

Im Gegensatz zum automatischen Stemming wird bei der Lemmatisierung, die auf **morphologische Grundform** reduziert.

- Grundform: Nominativ Singular, Infinitiv Präsenz etc.

Verfahren

- **Regel-basiert** für Wortformen
- **Wörterbuch-basiert** (Erkennung Wortform + Wörterbuch nötig)

Eigenschaften

- Vermeidet Over-/understemming
- Aufwendiger für die Implementation
- Jedoch: Stemming funktioniert in den meisten Fällen gut genug!

Kompositazerlegung

Beispiele

- Fußballweltmeisterschaft,
- Kompositazerlegung…

Zerlegung in morphologische Bestandteile

- Erhöht Recall

Verfahren:

- Wörterbuch-basiert
- Regelbasiert
  - Landschaft – s – malerei

Phrasenerkennung

Beispiele für Phrasen

- „White House“,
- „Deutsche Nationalbibliothek“,
- „Information Retrieval“

Indexierung als ein Indexterm

- erhöht Precision

Erweitert: Phrasenzusammenführung

- Information retrieval | retrieval of information

Verfahren:

- Statistisch (Kookkurrenz)
- Syntaktisch (grammatikalische Struktur)
- Wörterbuch-basiert

Soundex (Phonetische Korrektur)

Alternatives Indexierverfahren, das auf Aussprache basiert

1. Behalte den ersten Buchstaben des Terms.
2. Entferne folgenden Buchstaben, bzw. ignoriere sie:
   A, E, I, O, U, H, W, Y.
3. Ändere folgende Buchstaben in Zahlen:
   1. B, F, P, V → 1
   2. C, G, J, K, Q, S, X, Z → 2
   3. D,T → 3
   4. L → 4
   5. M, N → 5
   6. R → 6
4. Löse immer wieder gleiche Zahlenpaare auf.
5. Fülle das Ergebnis mit Nullen auf, damit insgesamt 4 Zeichen entstehen (1 Buchstabe, gefolgt von 3 Zahlen)

Soundex

Beispiele

- Britney → BRTN → **B635**
- Spears → SPRS → **S162**
- Superzicke → SPRZCK → S16222 → **S162**

- Ähnlich-klingende Worte werden gleichgesetzt
- Gut für Namensvarianten (Müller, Mueller, Miller)

Allerdings...

- ist Soundex sehr auf die englische Sprache ausgerichtet. (Klappt im Deutschen nicht sonderlich zuverlässig.)
- ist der Laut-Vergleich nur sehr grob.

Eigennamenerkennung

Was passiert, wenn wir Eigennamen nicht erkennen?

- Heath Ledger (machinell übersetzt) → Heide Kantholzträger
- Julia Roberts (Stemming) → Julia Robert
- Old Shatterhand, New York → ?

- Wir wollen die Indexierung **als ein Indexterm**
  - erhöht Precision
  - Erweitert: Namensdisambiguation

Verfahren:

- Normdateien
- regelbasiert

Folie von Vivien Petras

Beispiele aus Stock (2007), S. 248

Fehlertoleranz / Rechtschreibkorrektur

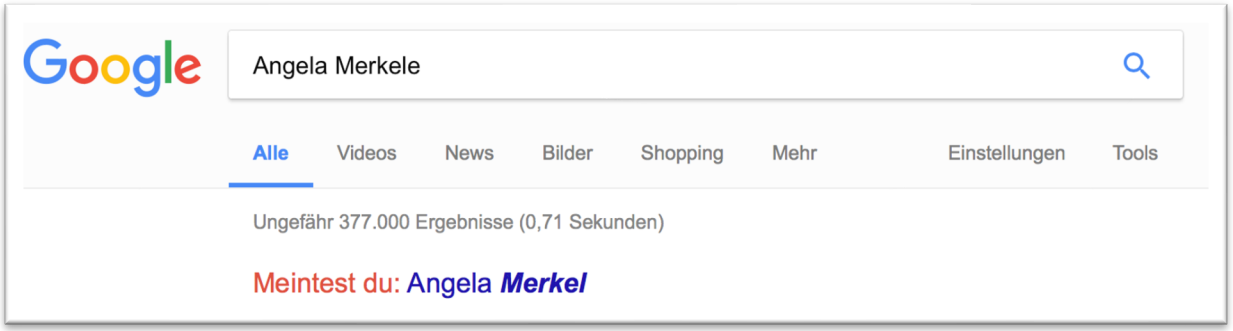

Typische Probleme

- Falscher Buchstabe
- Ausgelassener Buchstabe
- Buchstabendreher
- Zusätzlicher Buchstabe
- „Alles andere“

Lösungsansätze

- „nächste“ Alternative
- häufigste Alternative

Levenshtein-Distanz (Editierabstand)

Anzahl von Einfügen, Löschen und Ersetzen Operationen, um eine Zeichenkette in eine andere zu überführen

- Tier
- Toer (Ersetze i durch o)
- Tor (Lösche e)
- → **Levenshtein-Distanz ist 2**!

Nächste Alternative =

- niedrigste Anzahl von Editieroperationen

Häufigste Alternative =

- welche Wortkombinationen kommen häufiger vor in der Dokumentenkollektion

Beispiel-Pipelines (wo steckt der Fehler)

1. **Tokenizer**
2. **Stemming**
3. **Normalisierung**
   (z.B. Groß-/Kleinschreibung, Sonderzeichen)
4. **Stoppwort-Entfernung**

1. **Tokenizer**
2. **Phrasenerkennung**
3. **Normalisierung**
   (z.B. Groß-/Kleinschreibung, Sonderzeichen)
4. **Stemming**
5. **Stoppwort-Entfernung**

Zusammenfassung

- Ein Suchindex ist eine viel **effizientere Suchstruktur**, als eine Liste oder eine Term-Dokumentmatrix
- Die Indexierungspipeline arbeitet die nötigen Schritte ab
- Die Indexerstellung ist mit vielen **inhaltlichen** und **sprachlichen Problemen** behaftet für die es eine Reihe **intellektueller/ manueller** wie **technische/ statistische/ automatische Lösungen** gibt, z.B.
  - **Stoppwortlisten,**
  - **Stemming / Lemmatization**
  - **Kompositazerlegung**
  - **Phrasenerkennung**
  - **Eigennamenerkennung**
  - uvm.